

城市环境GNSS NLOS信号识别与修正：研究范式重构与实验框架设计

第一部分：核心思路的批判性审视与范式重构

1. 关于"模型选择"的正当性：从"用了什么模型"到"为什么是它"

你说"用Transformer做NLOS识别"，审稿人的第一个问题必然是：**NLOS问题的什么结构特性导致你必须用Transformer?**

NLOS问题的本质结构是什么？我们来拆解：

- 多卫星联合观测的异质性 (Heterogeneous Multi-Source Interaction)**：每颗卫星的NLOS状态并非独立——当车辆在城市峡谷中，某颗卫星被遮挡往往意味着相邻方位角的卫星处于类似状态。这是一种**集合级别的关系结构**，而非序列结构。
- 时变性与上下文依赖**：NLOS状态随车辆运动动态变化，且当前时刻的遮挡状态与前若干历史时刻的几何构型强相关。

如果你用**图神经网络 (GNN)**，理由可以是：卫星之间的几何关系天然构成图结构（节点=卫星，边=相对方位角/仰角关系），GNN的消息传递机制恰好能捕捉多卫星间的NLOS状态联合依赖性——这是一个**结构匹配 (structural inductive bias)** 的论据，可以从理论上写清楚。

如果你用**Transformer**，仅仅说"注意力机制能捕捉依赖"是不够的。你需要证明：NLOS识别中存在**长程、非局部的跨卫星依赖**，且这种依赖无法被局部卷积或固定邻域的GNN捕获。例如，你可以通过注意力权重的可视化，展示模型确实学到了"高仰角卫星与低仰角卫星之间的NLOS状态存在物理上合理的相关性"，从而给出**事后可解释性验证**。

范式建议：不要从"选模型"出发，而要从"NLOS问题的信息结构是什么"出发，再论证"什么模型的归纳偏置 (inductive bias) 与该信息结构匹配"。这才是通信领域审稿人认可的论证链。

2. 关于"识别+加权"的局限性：从"硬判决"到"误差分布估计"

$w = 1 - p(\text{NLOS})$ 这个公式的问题在于它犯了一个**信息损失谬误**：

- 问题一：分类概率 ≠ 误差幅度**。一颗卫星被判断为NLOS（概率=0.9），其实际伪距误差可能是5m，也可能是50m。但这两种情况在你的权重公式里完全相同。
- 问题二：阈值附近的不稳定性**。当 $p \approx 0.5$ 时，微小的模型输出变化会导致权重剧烈波动，导致定位结果不稳定。
- 问题三：忽略误差分布的形态**。NLOS误差通常是重尾分布（非高斯），其统计特性因反射面材质、卫星仰角、建筑高度而异。简单加权无法捕捉这种异质性。

通信领域的正确范式是：误差统计建模 (Error Distribution Estimation)。

你的模型输出不应该是一个"NLOS概率标量"，而应该是：

$$\hat{\theta}_i = (\hat{\mu}_i^{\text{NLOS}}, \hat{\sigma}_i^{\text{NLOS}}, \hat{p}_i^{\text{LOS}})$$

即：**对每颗卫星的伪距误差，输出其概率混合分布参数**——LOS概率、NLOS误差均值、NLOS误差方差。这样，后端定位器可以用**贝叶斯最优估计**而非简单加权来融合这些软信息，定位精度和理论深度都会大幅提升。

这一转变在学术上对应着从"分类任务"到"概率密度估计任务"的范式跃迁，与论文16（UWB Soft Multipath）的核心贡献一脉相承。

3. 关于"历史路径约束"的领域深度：运动-环境耦合建模

审稿人的问题：**LSTM和卡尔曼滤波的运动模型有什么本质区别？**

卡尔曼滤波的运动模型（如匀速/匀加速）是**参数固定的线性模型**，其先验假设与真实城市运动（频繁变速、转弯）不匹配。LSTM理论上可以学到非线性、非平稳的运动模式，这是数据驱动的优势。

但审稿人还会追问：**LSTM学到的是什么？能否解释？**

这里的关键洞察是：**城市环境中，车辆的运动状态与NLOS误差之间存在物理耦合**——

- 车辆沿直路行驶时：卫星几何构型相对稳定，NLOS状态变化慢
- 车辆转弯进入交叉口时：在几秒内，原本LOS的卫星可能被楼宇遮挡，NLOS误差骤增

这种**运动-遮挡耦合**是传统KF完全忽略的。如果你的LSTM不仅学习位置/速度的历史，而且**联合学习历史卫星几何构型的变化序列**，那么它就具备了预判"即将进入NLOS高发区"的能力。这才是超越KF的"环境智能"。

进一步的范式建议：将历史路径约束重新定位为"**运动-几何联合状态预测**"——不仅预测位置，还预测下一时刻的卫星NLOS概率先验，作为感知模块的先验输入，形成**时序反馈闭环**。

4. 关于"数据驱动 vs. 物理模型"的平衡：轻量物理先验的植入

你不需要推导完整的多径传播电磁场模型，但以下几个"轻量级物理先验"可以以极低成本融入数据驱动框架，并大幅提升论文的理论深度：

物理先验	如何轻量级融入	学术意义
卫星仰角-NLOS相关性	将仰角作为输入特征，并设计专门的角度编码层	低仰角卫星的NLOS先验概率更高，这是已有研究证实的统计规律
NLOS误差的单侧性	在损失函数中加入非负约束（NLOS使伪距偏大，非负误差）	利用误差的物理符号信息，这是纯数据驱动方法通常忽略的
卫星几何构型（DOP）	将实时DOP值作为定位融合层的调制权重	将经典GNSS理论中的几何精度因子与数据驱动无缝对接
建筑物镜像反射的仰角扰动	构造"伪仰角"特征，捕捉NLOS信号的方向偏差	来自论文18的几何先验，可解释NLOS误差的几何来源

这种"**物理先验作为结构性约束嵌入数据驱动模型**"的方式，比"纯物理模型"更灵活，比"纯数据驱动"更可解释，是目前通信/导航顶级期刊的主流范式。

5. 关于"系统性创新"的定位：从模块改进到框架贡献

你的研究可以被重新定位为以下系统级创新，而非单纯"改进识别模型"：

提出一个物理引导的NLOS软信息传播框架（Physics-Informed Soft Information Propagation Framework for NLOS Mitigation）

其核心创新点在于：

- 将NLOS问题从"二分类"重构为"误差概率密度估计"问题，从信息论角度证明软信息利用的理论优越性
- 设计运动-几何联合状态空间，将环境动态与NLOS误差统计耦合建模，超越传统KF与朴素LSTM
- 构建识别-融合-反馈的闭环优化架构，其中后端定位残差反馈用于在线校正前端感知模型的系统性偏差

优化后的核心研究思路（约350字）

本研究面向城市峡谷GNSS定位的核心挑战——NLOS伪距误差的感知与修正——提出一个物理引导的软误差传播框架（PI-SEP）。

不同于主流方法将NLOS识别视为二分类任务，本框架的核心洞察是：NLOS伪距误差是一个具有物理可解释结构的随机过程，其分布参数（均值、方差、形态）受卫星仰角、建筑几何、信号传播路径共同约束。因此，感知模块的目标不是输出"是/否"标签，而是为每颗卫星的伪距误差输出**条件概率密度函数的参数估计**，这些软信息携带了传统硬判决所丢弃的不确定性信息。

在模型选择上，本框架以**图注意力网络（GAT）**为骨干，其理论依据在于：多卫星观测天然构成几何图结构，卫星间的NLOS状态存在角度域的相关性（同方位角簇的卫星倾向于共享遮挡状态），GAT的注意力机制能够自适应地学习这种依赖结构，且注意力权重具有物理可解释性。

在融合层，框架采用**因子图优化**架构，以概率密度参数为观测噪声模型，实现贝叶斯意义下的最优融合——这比"1-p加权"具有严格的信息论优越性，可通过Fisher信息的理论推导正式证明。

框架的系统性贡献还体现在**反馈闭环**设计：后端定位的残差（预期误差与实际误差之差）被反馈至前端，用于检测感知模块的系统性偏差（如场景切换导致的分布偏移），触发在线微调。这将整个系统从"开环预测"提升为"闭环自适应估计"，在理论上对应于自适应滤波的在线辨识机制。

整体框架保持算法/流程创新的风格，同时通过物理先验的结构化嵌入（仰角编码、误差单侧约束、DOP调制）和严格的信息论分析，确保研究达到通信/导航领域顶级期刊的理论深度要求。

第二部分：详细实验框架设计


一、研究核心贡献陈述

- 范式贡献**：将城市GNSS NLOS误差处理从"二分类+加权"范式重构为"条件误差分布估计+贝叶斯软融合"范式，并从Fisher信息理论证明后者在最优估计意义下的严格优越性。
- 系统贡献**：提出识别-融合-反馈三模块闭环架构（PI-SEP），其中运动-几何联合状态预测模块将卫星遮挡动态与载体运动模式耦合建模，突破传统KF与LSTM对二者独立处理的局限。
- 可解释性贡献**：通过图注意力权重与误差分布参数的物理映射，实现对NLOS误差来源的几何可解释，为"数据驱动模型学到了什么物理规律"提供定量证据。

二、总体框架

原始GNSS观测量
(伪距、载噪比、多普勒、星历)

模块一：物理引导的软误差感知模块（PI-PEM）



模块间交互说明:

- **前向流:** 原始观测 → 软误差估计 → 贝叶斯融合定位
- **先验注入:** 模块二A的运动-几何预测为模块一提供时序先验（上一时刻的NLOS后验作为当前时刻先验的初始化）
- **反馈环路:** 模块三的残差分析反馈至模块一（在线微调）和模块二A（运动模型状态更新），形成闭环自适应系统

三、模块一：NLOS感知与误差分布建模（PI-PEM）

1.1 模块目标

不是: 输出"是否NLOS"的二值标签或单一概率标量

而是: 为每颗可见卫星 i 输出其伪距误差的**混合高斯分布参数**:

$$p(\epsilon_i | \mathbf{z} * i) = p_i^{\text{LOS}} \cdot \mathcal{N}(0, \sigma * \text{LOS}^2) + (1 - p_i^{\text{LOS}}) \cdot \mathcal{N}(\mu_i^{\text{NLOS}}, \sigma_i^{\text{NLOS}^2})$$

其中 $\mathbf{z}_i$ 为卫星 i 的观测特征向量，输出三元组 $(p_i^{\text{LOS}}, \mu_i^{\text{NLOS}}, \sigma_i^{\text{NLOS}})$ 作为软信息传递给后端。

为什么是混合高斯? LOS伪距误差近似高斯（测量噪声主导），NLOS误差均值为正（延迟偏置）且方差更大，混合模型在通信信道建模领域有充分的理论基础（与莱斯/瑞利信道的关系可在论文中简短论及）。

1.2 输入特征设计：物理先验的结构化嵌入

特征类别	具体特征	融入方式	物理依据
信号质量特征	载噪比 (C/N ₀)、信噪比变化率	直接输入	NLOS信号能量损耗导致C/N ₀ 下降
几何特征	卫星仰角 θ_i 、方位角 ϕ_i	仰角编码层 (参考位置编码设计)	低仰角↔高NLOS概率, 方位角↔建筑遮挡方向
伪距残差	伪距创新量 (观测-预测)	直接输入, 加入符号约束	NLOS误差单侧正偏
几何精度因子	PDOP、HDOP	全局调制权重	卫星几何构型的整体质量指标
环境上下文	来自模块二A的NLOS先验 q_i^{t-1}	与节点特征拼接	时序依赖: 历史遮挡状态约束当前估计
差分特征	双差伪距、时间差分伪距	辅助分支输入	差分运算消除公共误差, 增强NLOS特征对比度

物理约束的损失函数设计:

$$\mathcal{L} = \mathcal{L} * \text{NLL} + \lambda_1 \cdot \mathcal{L} * \text{sign} + \lambda_2 \cdot \mathcal{L}_{\text{calib}}$$

- $\mathcal{L}_{\text{NLL}}$: 负对数似然损失 (训练分布参数估计)
- $\mathcal{L}_{\text{sign}}$: 符号约束损失, 惩罚 $\hat{\mu}^{\text{NLOS}} < 0$ 的预测 (NLOS误差必须为正值, 源于信号绕射/反射导致传播路径延长)
- $\mathcal{L}_{\text{calib}}$: 校准损失 (ECE/Reliability Diagram), 确保输出概率与实际频率一致

1.3 模型架构：图注意力网络 (GAT) 的理论依据

问题的图结构: 将每个历元的卫星集合建模为图 $G = (V, E)$:

- 节点 v_i : 卫星 i , 携带特征向量 $\mathbf{z}_i$
- 边 (v_i, v_j) : 当 $|\phi_i - \phi_j| < \Delta\phi_{\text{threshold}}$ 时连接 (同方位角簇的卫星共享遮挡环境)

GAT的选择依据 (这是论文中必须写清楚的论证):

- 结构匹配性**: 同方位角卫星共享遮挡状态这一物理规律, 天然对应图上的邻域消息传递; MLP/CNN无法利用这种关系结构, 而GNN的归纳偏置与其完全匹配。
- 注意力机制的物理解释**: GAT中边的注意力权重 α_{ij} 可解释为"卫星 j 对估计卫星 i 的NLOS状态的贡献度"——这与角度域相关性的物理直觉一致, 且可通过实验验证 (展示注意力热图与实际遮挡关系的对应)。
- 相对于Transformer的优势**: Transformer默认所有卫星对之间都有注意力 ($O(N^2)$ 复杂度), 但物理上只有相近方位角的卫星才有遮挡相关性; GAT的稀疏图结构引入了这一物理先验, 减少了无意义的跨方位角注意力计算, 同时提升了模型的归纳偏置质量。

1.4 训练策略

数据构建：使用带有真值坐标的GNSS数据集（如UrbanNav、KAIST），通过与高精度参考（差分RTK或惯性导航）对比，计算每颗卫星的真实伪距误差，标注 $(p^{\text{LOS}}, \mu^{\text{NLOS}}, \sigma^{\text{NLOS}})$ 。

泛化能力保障：

- 跨城市迁移实验（在一个城市训练，另一个城市测试）
- 加入对抗数据增强（随机扰动卫星几何构型）
- 消融研究验证物理约束的贡献（有/无符号约束的精度对比）

四、模块二：软信息融合与轨迹优化

2A. 运动-几何联合状态预测

核心创新：区别于传统KF（只预测位置/速度）和朴素LSTM（只预测位置序列），本子模块联合预测：

$$\hat{\mathbf{s}} * t + 1 = f([\mathbf{x} * t - T : t, \mathbf{G}_{t-T:t}])$$

其中 $\mathbf{x}$ 为位置状态， $\mathbf{G}$ 为卫星几何矩阵（各卫星仰角/方位角的历史序列）。

输出不仅包含位置预测，还包含**下一时刻各卫星的NLOS先验概率预测** q_i^t ，作为模块一的时序先验输入。

架构：Temporal Convolutional Network (TCN) 或 Transformer Encoder（此处时序建模，输入是固定长度序列，Transformer的合理性更强）。

为什么TCN/Transformer优于LSTM：TCN的感受野可精确控制（对应物理上的相关时间窗口），且并行计算效率更高；相比之下LSTM的梯度传播问题在长序列上仍存在。这是在序列预测子模块中选用Transformer的正当性——注意区分“整体架构”和“子模块”，论证粒度要对应。

2B. 因子图软信息融合定位器

为什么用因子图优化，而非加权最小二乘：

方法	如何处理NLOS软信息	局限性
加权最小二乘 (WLS)	$w_i = 1/\sigma_i^2$ (仅用方差)	无法利用均值偏差 μ_i ，且假设误差高斯
鲁棒估计 (Huber/Tukey)	降低大残差权重	不使用软信息，依赖残差大小而非先验
因子图优化 (本方法)	将完整分布 (p_i, μ_i, σ_i) 嵌入因子节点	贝叶斯意义下的最优（在分布正确时）

因子图构建：

- 变量节点：位置状态 $\mathbf{x}_t$
- 因子节点1：卫星伪距观测因子（以混合高斯为噪声模型）
- 因子节点2：运动先验因子（来自模块二A的预测）
- 因子节点3：高度约束因子（城市场景下垂直运动有限）

信息论优越性的理论证明（论文中的关键定理）：

可以证明，当伪距误差服从混合高斯分布时，使用完整分布参数的因子图优化所获得的Fisher信息量严格不小于仅使用方差信息的WLS，即：

$$\mathcal{I} * \text{FG}(\mathbf{x}) \geq \mathcal{I} * \text{WLS}(\mathbf{x})$$

等号当且仅当 $p_i^{\text{LOS}} \in 0, 1$ 时成立（退化为硬判决）。这一不等式为软信息融合提供了**严格的信息论优越性证明**，是区别于纯工程方法的理论贡献。

五、模块三：残差反馈与在线校正

动机：部署时场景可能与训练集分布不同（如新城市、极端天气），导致感知模块的输出产生系统性偏差。

机制：

- 计算定位残差（或创新序列）： $\boldsymbol{\nu}_t = \mathbf{z}_t - h(\hat{\mathbf{x}}_t)$
- 用滑动窗口内的残差统计量（均值、方差、偏度）检测分布偏移
- 若检测到偏移，触发：
 - 感知模块输出的**后验修正**（贝叶斯更新偏差参数）
 - 或轻量级在线微调（仅更新模块一的最后几层）

理论依据：对应自适应滤波理论中的“新息序列白化”检验，将数据驱动模型的在线校正纳入了经典估计理论的框架内。

六、实验设计与验证

6.1 数据集

数据集	场景特性	用途
UrbanNav (HKUST)	香港城市峡谷，含IMU/LiDAR参考	主要训练/测试集
KAIST Urban Dataset	韩国城市，多传感器同步	跨域泛化测试
GNSS-SDR仿真数据	可控NLOS场景，精确误差标注	消融研究、理论验证
自采数据（可选）	拉斯维加斯城市场景	新场景泛化验证

6.2 对比基线（体现领域深度）

基线类别	具体方法	测试目的
经典物理方法	仰角加权（EWM）、RAIM故障检测	证明超越传统GNSS方法的增益
经典数据驱动	SVM-NLOS分类+WLS、LSTM轨迹平滑	证明软信息框架超越硬判决方法
SOTA混合方法	论文中引用的最新方法（如基于CNN/ResNet的NLOS识别+加权）	证明系统级框架超越单模块改进

基线类别	具体方法	测试目的
消融变体	去除物理约束损失 / 去除反馈模块 / 用WLS替换因子图	验证每个创新组件的单独贡献


6.3 评估指标（超越单一定位精度）

指标类别	具体指标	评估目的
定位精度	RMSE (2D/3D)、CEP50、CEP95	基本性能
分布质量	NLL（负对数似然）、校准误差（ECE）、可靠性图	软信息输出的质量
鲁棒性	最差10%场景的精度、重NLOS场景下的精度	尾部性能
泛化能力	跨城市迁移精度降幅	泛化评估
可解释性	注意力权重与实际遮挡几何的相关系数	物理可解释性验证
在线校正效果	分布偏移检测前后的精度变化	反馈模块贡献

七、组会汇报建议与创新点总结

7.1 如何用示意图传达"范式创新"

建议制作一张**范式对比图**（横轴：信息层次；纵轴：处理深度）：



核心信息：随着对误差不确定性的建模深度提升，定位系统的理论上界（Cramér-Rao Lower Bound）持续降低。这是一张图就能讲清楚的核心贡献。

7.2 应对审稿人可能的质疑

质疑1: "为什么不用更简单的模型？"

回答思路：在定位融合层，简单模型（WLS）无法利用误差均值信息（ μ_i^{NLOS} ），这是理论上的损失，可用Fisher信息不等式定量证明。在感知层，图结构是数据的自然表示（卫星间确实有角度域相关性），更简单的MLP相当于忽略了这一先验知识——我们可以通过消融实验定量展示"加入图结构"的精度提升。

质疑2: "你的方法在未见场景下表现如何？"

回答思路：跨城市实验数据；反馈校正模块专为此设计，可展示在分布偏移场景下，有/无反馈模块的精度对比，定量证明闭环机制的泛化增益。

质疑3: "物理约束是否真的有用？还是模型自己学到了？"

回答思路：消融实验中去除符号约束损失 $\mathcal{L}_{\text{sign}}$ ，对比在小数据量场景下的性能——物理约束的价值在数据稀缺时体现得最为明显（这也是物理先验vs纯数据驱动的经典论证方式）。

八、最终总结：核心贡献的学术表述

本研究的核心学术贡献可表述为：

本文提出了一种面向城市峡谷GNSS定位的物理引导软误差传播框架（PI-SEP），其主要贡献体现在三个层面：

（理论层面） 将城市环境NLOS伪距误差的感知问题从"二分类"范式重构为"条件混合分布参数估计"范式，并通过Fisher信息分析严格证明了软误差信息在贝叶斯最优估计意义下相对于硬判决的理论优越性，为软信息辅助GNSS定位提供了信息论基础。

（系统层面） 设计了识别-融合-反馈三模块闭环架构：感知模块以图注意力网络刻画多卫星NLOS状态的角度域相关结构，融合模块以因子图优化框架实现软误差信息的贝叶斯最优利用，反馈模块基于创新序列检测实现对分布偏移场景的在线自适应校正。

（方法层面） 提出了运动-几何联合状态预测方法，将载体运动模式与卫星遮挡几何动态耦合建模，突破了传统方法对运动先验与信号感知相互独立的假设，为时序GNSS定位提供了物理上更一致的系统状态表示。

写在最后：这个框架的核心价值在于，你始终能够回答审稿人的根本性问题——每一个设计决策，都有对应的物理直觉、数学依据，或信息论证明。这正是通信/导航领域顶级期刊与计算机方向"换模型"论文的本质分野。

这两个问题都触及了框架设计中真正容易被审稿人抓住的逻辑漏洞，很值得深入讨论。

问题一：为什么不用一个统一的端到端大模型？

这个问题的本质是在问：**模块化设计（GAT + 独立时序模块）的理由是什么，而不仅仅是"两个模块用了两种架构"的表面现象。**

如果你在论文中无法回答这个问题，审稿人会认为架构选择是随意拼凑的。

先承认问题的合理性

确实，存在一类模型可以统一处理时空联合建模——**时空图神经网络（ST-GNN）**，如STGAT、DCRNN等。它们在交通流预测等领域已有成熟应用。审稿人提出"为什么不用ST-GNN端到端建模"是完全合理的。

如果你无法给出有力的反驳，这个架构设计就是脆弱的。

深层原因：两个模块解决的是两类结构根本不同的问题

关键在于区分两件事：

模块一（GAT）解决的是：在固定时刻 t ，多颗卫星之间的NLOS状态联合推断。

这是一个**集合上的关系推理**问题。输入是无序的卫星集合，集合大小随时刻变化（卫星升落），图的拓扑结构（哪些卫星方位角相近）也随时刻变化。这个问题要求**置换等变性（permutation equivariance）**——卫星编号的排列顺序不应影响推断结果，而GAT天然满足这一性质。

模块二A解决的是：在固定卫星几何历史序列下，预测下一时刻的系统状态。

这是一个有序时间序列的状态预测问题。输入是按时间严格排序的历史状态序列，时间方向上存在明确的因果依赖。这个问题要求时序因果性（temporal causality），与“哪颗卫星是第几号”无关。

这两种结构的归纳偏置是正交的，强行统一会造成以下问题：

一个统一的ST-GNN需要在每个时刻构建固定的时空图。但卫星可见集合是动态变化的——今天能看到卫星A，明天可能看不到。时空图的节点集随时间变化，使得标准ST-GNN的节点对齐（node alignment）成为一个难以处理的技术问题，而这个问题本身并非研究目标。

更关键的一个逻辑原因：模块间存在方向性反馈依赖

模块二A的输出（下一时刻NLOS先验预测）是模块一的输入先验。这形成了一个时序上的单向依赖链：

[t-1时刻GAT输出] → [模块二A预测t时刻先验] → [t时刻GAT输入] → [t时刻GAT输出]

如果将两个模块合并为一个端到端模型，这个方向性依赖会变成模型内部的自环（self-loop），在训练时需要处理信息泄露（用未来信息预测当前状态）或截断梯度的问题，使训练变得不稳定且难以验证。模块化设计将这一依赖关系显式化，反而是更清晰、可验证的系统结构。

还有一个实践中重要的原因：训练数据的异质性

模块二A的时序预测训练不需要NLOS误差标签——它只需要大量的轨迹数据（位置、速度、卫星几何历史），这类数据远比带有精确伪距误差真值的NLOS标注数据丰富。模块化设计允许两个模块使用不同规模、不同来源的数据集分别预训练，然后联合微调。端到端统一模型则必须使用同一批需要昂贵标注的数据，大幅限制了可利用的信息量。

如何在论文中表述

不要说“GAT处理空间，Transformer处理时序”，而要说：

本框架的模块化设计源于NLOS问题中两类结构异质性的显式分离：空间模块处理固定时刻下的多源关系推理（置换等变），时序模块处理状态演化的因果预测（时序有序）。将二者合并为统一的时空图模型会引入节点动态对齐问题，且使模块间的先验反馈依赖退化为模型内部自环，破坏因果结构的可验证性。

这个论述可以挡住“为什么不统一”的质疑，同时将模块化本身定位为一种有意识的系统设计选择，而非能力不足的折衷。

问题二：反馈模块与自适应卡尔曼滤波的本质区别

这个问题更为深刻，也更危险——如果你的回答是“差不多，只是换成了神经网络”，那这个模块就没有存在的学术价值。

自适应卡尔曼滤波（AKF）实际在做什么

以经典的Sage-Husa自适应滤波为例，它的核心操作是：根据创新序列 $\nu_t = \mathbf{z}_t - H\hat{\mathbf{x}}_t$ 的统计特性，在线估计测量噪声协方差 $\mathbf{R}_t$ 和过程噪声协方差 $\mathbf{Q}_t$ ：

$$\hat{\mathbf{R}} * t = (1 - d_t)\hat{\mathbf{R}} * t - 1 + d_t(\nu_t \nu_t^T - H \mathbf{P} * t | t - 1 H^T)$$

这个操作有两个根本性的隐含假设：

假设一：模型结构是正确的，只有参数偏移了。 AKF假设系统仍然是线性高斯的，NLOS误差仍然可以用调整后的高斯噪声来描述，需要适应的只是这个高斯分布的均值和方差。

假设二：适应发生在二阶统计量层面。 $\mathbf{R}_t$ 是协方差矩阵，AKF本质上是在做**二阶矩匹配**，对分布的偏度、峰度、多模态性等高阶结构视而不见。

PI-SEP反馈模块超越AKF的三个层次

层次一：适应的对象不同——从参数适应到函数类适应

AKF在**固定的参数族**（高斯族）内做参数估计。当NLOS误差实际上是重尾分布或双峰分布时，AKF无论如何调整 $\mathbf{R}$ ，都无法正确表示这种分布，只能给出一个在最小二乘意义下最接近的高斯近似。

PI-SEP的感知模块输出是神经网络参数化的混合高斯分布，其参数空间远比单个 $\mathbf{R}$ 矩阵丰富。反馈触发的在线微调，本质上是在调整**生成分布的函数形式**，而非仅仅调整某个固定形式的参数。用泛函分析的语言来说，AKF在有限维参数空间内搜索，PI-SEP反馈在函数空间（无穷维）的某个紧子集上搜索。

层次二：检测目标不同——从二阶矩偏移到分布结构偏移

AKF通过监测创新序列的协方差来判断是否需要适应，即检测 $\mathbb{E}[\boldsymbol{\nu}_t \boldsymbol{\nu}_t^\top]$ 是否偏离理论值。这只能捕捉方差层面的变化。

PI-SEP反馈模块可以计算创新序列的**完整分布统计量**：均值、方差、偏度、峰度，乃至用KL散度或Wasserstein距离检测与历史分布的整体偏移。这使得它能够检测AKF无法感知的分布结构变化——例如，从单一NLOS反射（单峰误差分布）切换到双重反射（双峰误差分布）场景，二阶矩可能变化不大，但分布形态已完全不同，AKF会“视而不见”而PI-SEP会触发适应。

层次三：适应的语义不同——从噪声统计适应到场景感知适应

这是最本质的区别，也是通信/导航领域审稿人最认可的论点。

AKF的适应是**盲目的统计适应**——它不知道为什么创新序列变大了，只知道“需要增大 $\mathbf{R}$ ”，适应结果没有物理语义。

PI-SEP反馈触发的神经网络微调，更新的是GAT的图注意力权重，这些权重具有物理语义——它们对应“在当前场景下，哪些方位角的卫星更容易受到遮挡”。适应的结果是感知模块重新学习了当前城市几何结构下的遮挡模式，而不只是“调大了噪声方差”。

用一个类比来说：AKF的适应相当于“知道天气变坏了，把安全余量调大”；PI-SEP的适应相当于“知道进入了一个新城区，重新学习了这里的建筑遮挡规律”。前者是被动统计补偿，后者是主动场景理解更新。

这个区别如何以理论方式写入论文

可以从模型误设（model misspecification）的角度正式化这个区别：

设真实伪距误差分布为 $p^*(\epsilon)$ ，AKF假设其属于高斯参数族 $\mathcal{F}_{\text{Gaussian}}$ ，当 $p^*(\epsilon) \notin \mathcal{F} * \text{Gaussian}$ 时，AKF的适应结果是 $\arg \min_{f \in \mathcal{F} * \text{Gaussian}} D * \text{KL}(p^*|f)$ ，即高斯族内的最优近似，存在不可消除的近似误差。PI-SEP感知模块对应更大的函数类 $\mathcal{F} * \text{NN} \supset \mathcal{F} * \text{Gaussian}$ ，在分布偏移时，反馈微调在 $\mathcal{F}_{\text{NN}}$ 内搜索，理论上可将近似误差压缩至任意小（在神经网络通用逼近定理的保证下）。

这段话写成定理的形式，就是反馈模块超越AKF的严格理论依据。

在组会或论文中的简洁表述

如果需要一句话概括，可以这样说：

自适应卡尔曼滤波在**正确模型的参数空间**内适应；PI-SEP反馈模块在**模型结构本身**上适应——前者假设误差"仍然是高斯的，只是方差变了"，后者能够检测并响应"误差已经不再是高斯的"这一模型误设事件。

这个区别回答了审稿人"你的反馈模块贡献在哪里"的追问，同时将其定位在一个经典问题（模型误设检测与自适应估计）的理论框架下，而不是一个工程技巧。